



ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT

BÁO CÁO TỔNG KẾT
CRYPTO MARKET SCENARIO SIMULATION MODEL
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN
NĂM 2024

TT	Họ tên	MSSV	Đơn vị	Nhiệm vụ	Điện thoại	Email
1.	Phạm Quốc Đạt	K224131523	Khoa Toán Kinh tế	Nhóm trưởng	0365120341	datpq22413@st.uel.edu.vn
2.	Nguyễn Lê Minh Hiếu	K224131528	Khoa Toán Kinh tế	Tham gia	0839309807	hieunlm22413@st.uel.edu.vn
3.	Đặng Anh Duy	K224131578	Khoa Toán Kinh tế	Tham gia	0393698381	duyda22413c@st.uel.edu.vn

LỜI CAM ĐOAN

Chúng tôi cam đoan bài nghiên cứu này do nhóm sinh viên chúng tôi thực hiện. Các đoạn trích dẫn và số liệu sử dụng trong đề tài này đều được dẫn nguồn và có độ chính xác cao nhất trong phạm vi hiểu biết của chúng tôi. Những nội dung và kết quả nghiên cứu là trung thực do nhóm tác giả nỗ lực nghiên cứu và tận dụng kiến thức thực tế có được. Ngoài ra, trong bài báo cáo có sử dụng một số nguồn tài liệu tham khảo được trích dẫn nguồn và chú thích rõ ràng.

Nhóm tác giả xin hoàn toàn chịu trách nhiệm trước nhà Trường và Khoa về sự cam đoan này.

Nhóm tác giả

MỤC LỤC

LỜI CAM ĐOAN	2
DANH MỤC BIỂU ĐỒ, HÌNH ẢNH	5
DANH MỤC CÁC TỪ VIẾT TẮT	6
CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI NGHIÊN CỨU	7
1.1. Lý do chọn đề tài.....	7
1.2. Mục tiêu nghiên cứu.....	8
1.2.1. Mục tiêu chung	8
1.2.2. Mục tiêu cụ thể	8
1.3. Đối tượng và phạm vi nghiên cứu.....	8
1.4. Ý nghĩa của nghiên cứu.....	9
1.5. Bố cục của nghiên cứu	10
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT	11
2.1. Cơ sở lý thuyết:	11
2.1.1. Thư viện XGBoost:	11
2.1.2. Học tăng cường (Boosting)	14
2.1.3. Các chỉ số rủi ro tài chính.....	16
2.1.4. Các mô hình dự báo tài chính liên quan	18
2.1.5. XGBoost trong dự báo chuỗi thời gian và tài chính:	21
2.2. Phương pháp nghiên cứu:.....	23
2.2.1. Quy trình nghiên cứu:	23
2.2.2. Xác định lý thuyết nền:	24
2.2.3. Thu thập dữ liệu:	25
2.2.4. Xây dựng mô hình:	27
CHƯƠNG 3: KẾT QUẢ NGHIÊN CỨU	32
3.1. Giới thiệu.....	32
3.2. Phương pháp luận.....	32
3.2.1. Dữ liệu.....	32
3.2.2. Mô hình dự báo	33
3.2.3. Quy trình thực hiện	33
3.3. Kết quả phân tích	35
3.3.1. Hiệu suất mô hình	35
3.3.2. Dự báo kết quả	36
3.3.3. Phân tích rủi ro	38

3.3.4. Kiểm tra tính đồng nhất của dữ liệu log-return và giá ban đầu	38
3.3.5. Đồ thị và phân tích trực quan	39
CHƯƠNG 4: KẾT LUẬN VÀ KHUYẾN NGHỊ.....	44
4.1. Khuyến nghị về lựa chọn đồng coin.....	44
4.1.1. Ưu tiên các đồng coin có biến động ổn định và thanh khoản cao	44
4.1.2. Cân trọng với các đồng coin có biến động mạnh.....	44
4.1.3. Đánh giá các yếu tố cơ bản (fundamental analysis)	44
4.2. Khuyến nghị về quản trị rủi ro	44
4.2.1. Sử dụng các chỉ số định lượng để đo lường rủi ro	44
4.2.2. Quan sát các chỉ số rủi ro bổ sung.....	45
4.2.3. Quản trị danh mục đầu tư	45
TÀI LIỆU THAM KHẢO.....	46

DANH MỤC BIỂU ĐỒ, HÌNH ẢNH

Hình 3.2.1. Bộ dữ liệu đầu vào

Hình 3.3.1 Các yếu tố tác động đến khả năng sinh lời của các công ty chứng khoán

Hình 3.3.2. Kết quả dự báo log-return 24 giờ tiếp theo

Hình 3.3.3. Các chỉ số rủi ro với mức ý nghĩa 5%

Hình 3.3.4. Kiểm tra tính đồng nhất

Hình 3.3.5. Biểu đồ phân phối log-return (Hourly)

So sánh dự báo giá Coin 1 với thực tế

So sánh dự báo giá Coin 2 với thực tế

So sánh dự báo giá Coin 3 với thực tế

DANH MỤC CÁC TỪ VIẾT TẮT

KÝ HIỆU VIẾT TẮT	DIỄN GIẢI	
	TIẾNG ANH	TIẾNG VIỆT
PnL	Cumulative Profit and Loss	Lợi nhuận và lỗ tích lũy
TimeGAN	Time-series Generative Adversarial Networks	Mạng đối kháng tạo chuỗi thời gian
RCGAN	Recurrent Conditional GAN	GAN có điều kiện tuần hoàn
RNN	Recurrent Neural Network	Mạng nơ-ron hồi quy
LSTM-GAN	Long short-term memory and generative adversarial network	Bộ nhớ dài hạn ngắn và mạng lưới đối kháng sinh thành
XGBoost	eXtreme Gradient Boosting	Tăng cường độ dốc cực đại
GBDT	Gradient Boosting Decision Trees	Cây quyết định tăng cường độ dốc
XGBR	XGBoost Regression	Hồi quy XGBoost
VaR	Value at Risk	Giá trị rủi ro
ES	Expected Shortfall	Sự thiếu hụt kỳ vọng
MDD	Maximum Drawdown	mức suy giảm tối đa

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI NGHIÊN CỨU

1.1. Lý do chọn đề tài

Trong bối cảnh tài chính hiện đại, tiền điện tử đã và đang trở thành một trong những lĩnh vực thu hút sự quan tâm mạnh mẽ từ cả các nhà đầu tư cá nhân lẫn các tổ chức tài chính trên toàn cầu. Sự gia tăng nhanh chóng về vốn hóa thị trường cùng với việc các mạng lưới thanh toán lớn bắt đầu chấp nhận tiền điện tử như một phương thức giao dịch hợp pháp đã minh chứng cho tầm ảnh hưởng ngày càng lớn của loại tài sản này. Tuy nhiên, đằng sau sự phát triển vượt bậc đó là những thách thức rất lớn liên quan đến tính bất ổn và biến động mạnh mẽ của thị trường. Điều này làm dấy lên nhiều câu hỏi về khả năng dự báo và đánh giá rủi ro của các tài sản kỹ thuật số.

Sự biến động lớn trong giá trị của tiền điện tử không chỉ tạo ra cơ hội sinh lời nhanh chóng mà còn gây ra rủi ro thiệt hại đáng kể. Vì thế, các nhà đầu tư không chỉ cần các công cụ để ra quyết định mà còn cần các mô hình mô phỏng đáng tin cậy nhằm phân tích và đánh giá các kịch bản thị trường. Một mô hình như vậy sẽ giúp tạo ra các dữ liệu thị trường tổng hợp có độ chính xác cao, mô phỏng lại các chuỗi log-return của các đồng tiền điện tử hàng đầu như Bitcoin, từ đó đưa ra dự đoán và đánh giá rủi ro một cách toàn diện. Bên cạnh đó, các cơ quan quản lý tài chính cũng có nhu cầu cao trong việc sử dụng các mô hình mô phỏng để giảm thiểu rủi ro mất mát lớn trên thị trường. Đặc biệt, với sự tham gia của các tổ chức lớn như Antalpha, việc phát triển một mô hình có khả năng tạo dữ liệu tổng hợp đáng tin cậy sẽ giúp nâng cao khả năng dự đoán và quản lý rủi ro, hỗ trợ quá trình ra quyết định về chính sách giám sát thị trường tiền điện tử.

Việc xây dựng mô hình Crypto Market Scenario Simulation Model không chỉ mang lại ý nghĩa trong học thuật mà còn có khả năng ứng dụng thực tiễn rất cao. Trước hết, mô hình này giúp tạo ra các dữ liệu thị trường tổng hợp với độ chính xác cao, từ đó kiểm tra tính phù hợp của các chiến lược giao dịch thông qua việc so sánh phân phối lợi nhuận (PnL) giữa dữ liệu thực và dữ liệu tổng hợp. Điều này sẽ giúp các nhà đầu tư kiểm chứng tính hiệu quả của các chiến lược trước khi áp dụng vào thực tế. Hơn nữa, trong bối cảnh thị trường tiền điện tử ngày càng phức tạp, các mô hình tạo sinh (Generative Models) như TimeGAN và RCGAN đang nổi lên như những giải pháp mạnh mẽ để mô phỏng các chuỗi thời gian đa biến. Bằng cách áp dụng các thuật toán học sâu (Deep Learning) và mô hình tạo sinh, đề tài sẽ giúp cải thiện độ chính xác trong

việc dự đoán sự biến động của thị trường tiền điện tử, từ đó xây dựng được các công cụ quản lý rủi ro hiệu quả.

Việc phát triển mô hình mô phỏng thị trường tiền điện tử sẽ mở ra nhiều hướng nghiên cứu trong tương lai. Mô hình có thể được áp dụng trong việc dự báo xu hướng thị trường, quản lý danh mục đầu tư, và định giá các công cụ tài chính phái sinh. Ngoài ra, khả năng mô phỏng chính xác biến động giá tiền điện tử cũng sẽ hỗ trợ việc xây dựng các hệ thống giao dịch tự động (algorithmic trading systems), từ đó giúp tối ưu hóa lợi nhuận và giảm thiểu rủi ro. Việc kết hợp các mô hình dự đoán với các chiến lược giao dịch tiên tiến sẽ tạo ra một hệ sinh thái tài chính số bền vững và hiệu quả hơn.

1.2. Mục tiêu nghiên cứu

1.2.1. Mục tiêu chung

Xây dựng và phát triển một mô hình mô phỏng dữ liệu thị trường tiền điện tử có độ chính xác cao, tập trung vào việc tái tạo các chuỗi log-return của các đồng tiền điện tử hàng đầu.

1.2.2. Mục tiêu cụ thể

- Xây dựng mô hình tạo sinh (Generative Model) để mô phỏng dữ liệu log-return trong khoảng thời gian 24 giờ của các đồng tiền điện tử.
- Sử dụng mô hình mô phỏng để tạo ra các kịch bản rủi ro khác nhau.
- Đánh giá độ chính xác của mô hình.
- Đề xuất và thử nghiệm các mô hình tạo sinh mới hoặc cải tiến từ các mô hình hiện có.

1.3. Đối tượng và phạm vi nghiên cứu

- Đối tượng: Mô phỏng dữ liệu chuỗi thời gian tài chính, cụ thể là chuỗi log-return của các đồng tiền điện tử thông qua các mô hình tạo sinh (Generative Models) như:

+ TimeGAN (Time-series Generative Adversarial Networks)

+ RCGAN (Recurrent Conditional GAN): Kết hợp mạng nơ-ron hồi quy (RNN) và GAN để tạo ra chuỗi thời gian tổng hợp có tính chính xác cao.

+ Các mô hình khác như GAN truyền thống, LSTM-GAN, Transformer GAN: Được xem xét và phân tích để so sánh hiệu quả.

- Phạm vi nghiên cứu: Xây dựng mô hình mô phỏng chuỗi log-return của tiền điện tử nhằm phản ánh chính xác sự biến động của thị trường trong khoảng thời gian 24 giờ. Đánh giá độ chính xác của mô hình thông qua việc so sánh phân phối lợi nhuận (PnL) từ dữ liệu mô phỏng và dữ liệu thực. Đặc biệt là 3 đồng tiền điện tử có khối lượng giao dịch lớn nhất như Bitcoin và hai đồng tiền phổ biến khác.

- Phạm vi thời gian: 7 năm và được chia thành các khung thời gian 24 giờ liên tục bằng kỹ thuật cửa sổ trượt (rolling window). Giai đoạn nghiên cứu không bao gồm thời kỳ COVID-19 và giai đoạn nới lỏng định lượng (Quantitative Easing) để tránh sai lệch dữ liệu.

1.4. Ý nghĩa của nghiên cứu

Nghiên cứu này góp phần phát triển các phương pháp mô phỏng dữ liệu thị trường tiền điện tử dựa trên các mô hình học sâu như TimeGAN, RCGAN, LSTM-GAN, và các mô hình tạo sinh khác. Từ đó nghiên cứu có thể được áp dụng để kiểm chứng các lý thuyết về sự biến động và dự báo giá trị trong thị trường tiền điện tử.

Với việc xây dựng mô hình mô phỏng chính xác, nhà đầu tư có thể tạo ra các kịch bản thị trường giả lập, từ đó tối ưu hóa chiến lược giao dịch và dự báo rủi ro trong các tình huống biến động mạnh, giảm thiểu các sai sót do yếu tố cảm xúc hay yếu tố con người. Giúp nhà đầu tư hiểu rõ hơn về tính chất biến động của thị trường tiền điện tử, từ đó ra quyết định đầu tư an toàn và thông minh hơn.

Sau khi thực hiện nghiên cứu, nhóm nhận thấy việc tiến hành phân tích, đánh giá và dự đoán tiền điện tử không chỉ mang lại giá trị khoa học trong lĩnh vực tài chính ứng dụng và trí tuệ nhân tạo, mà còn góp phần thúc đẩy quản lý rủi ro hiệu quả, tối ưu hóa chiến lược đầu tư, đồng thời nâng cao nhận thức của cộng đồng về đầu tư thông minh trong thị trường tiền điện tử.

1.5. Bố cục của nghiên cứu

Chương 1: Giới thiệu chung về bài nghiên cứu

Chương 2: Thực trạng diễn biến giai đoạn nghiên cứu, các định nghĩa và tổng quan các nghiên cứu đi trước

Chương 3: Dữ liệu và thiết lập mô hình

Chương 4: Kết quả nghiên cứu

Chương 5: Kết luận và đánh giá.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Cơ sở lý thuyết:

2.1.1. Thư viện XGBoost:

XGBoost (eXtreme Gradient Boosting) là một thư viện mã nguồn mở dành cho học máy, được phát triển nhằm tối ưu hóa quá trình huấn luyện và dự đoán trên tập dữ liệu lớn. Thuật toán này được xây dựng dựa trên Gradient Boosting Decision Trees (GBDT), một phương pháp học có giám sát sử dụng nhiều mô hình cây quyết định nhỏ kết hợp lại để tạo ra một mô hình mạnh mẽ hơn. Điểm khác biệt của XGBoost nằm ở gradient descent – một kỹ thuật giúp tối ưu hóa sai số trong quá trình huấn luyện.

XGBoost được phát triển bởi Tianqi Chen tại Đại học Washington, với mục tiêu tăng tốc độ xử lý, cải thiện hiệu suất và mở rộng khả năng áp dụng trên dữ liệu lớn. So với các phương pháp boosting truyền thống, XGBoost mang lại nhiều cải tiến quan trọng như:

- + Tính toán song song và phân tán, giúp mô hình xử lý dữ liệu nhanh hơn.
- + Tối ưu bộ nhớ, nhờ vào thuật toán prefetching và cấu trúc dữ liệu đặc biệt.
- + Regularization (L1, L2), giúp giảm thiểu overfitting, tăng khả năng tổng quát hóa của mô hình.

Bên cạnh đó, XGBoost hỗ trợ nhiều ngôn ngữ lập trình như C++, Python, R, Java, Scala, Julia, giúp nó trở thành một công cụ mạnh mẽ cho các bài toán học máy, phân tích dữ liệu và dự báo. Nhờ những ưu điểm trên, XGBoost được đánh giá là một trong những thư viện hàng đầu trong lĩnh vực học máy, được sử dụng rộng rãi trong các cuộc thi khoa học dữ liệu như Kaggle cũng như trong thực tế ở nhiều ngành công nghiệp khác nhau. Thuật toán này đã thay đổi cách các tổ chức và doanh nghiệp sử dụng Machine Learning để giải quyết các bài toán thực tế. Dưới đây là một số hệ quả quan trọng của XGBoost:

1. Cải thiện dự báo tài chính và phát hiện gian lận: XGBoost được ứng dụng rộng rãi trong lĩnh vực tài chính, đặc biệt trong việc dự báo xu hướng thị trường và quản lý rủi ro. Thuật toán giúp các tổ chức tài chính phân tích dữ liệu lịch sử, xác định các yếu tố ảnh hưởng đến giá cả, từ đó xây dựng mô hình dự báo chính xác hơn. Ngoài ra,

XGBoost còn đóng vai trò quan trọng trong hệ thống phát hiện gian lận tài chính. Bằng cách phân tích hàng triệu giao dịch mỗi ngày, thuật toán này có thể nhanh chóng nhận diện các hành vi đáng ngờ, từ đó hỗ trợ ngân hàng và tổ chức tài chính ngăn chặn các giao dịch gian lận kịp thời.

2. Giúp tối ưu hóa trong lĩnh vực thương mại điện tử và tiếp thị số: XGBoost giúp nâng cao trải nghiệm khách hàng bằng cách tối ưu hệ thống gợi ý sản phẩm. Các nền tảng như Amazon, Shopee và Lazada sử dụng XGBoost để phân tích hành vi mua sắm của khách hàng, từ đó đưa ra các đề xuất sản phẩm cá nhân hóa, giúp tăng tỷ lệ mua hàng và doanh thu. Bên cạnh đó, thuật toán này còn được sử dụng để tối ưu hóa chiến dịch quảng cáo, giúp doanh nghiệp dự đoán tỷ lệ nhấp chuột (CTR) và phân phối quảng cáo hiệu quả hơn, giảm chi phí tiếp thị nhưng vẫn đạt hiệu suất cao.

3. Hỗ trợ chẩn đoán y tế và dự báo dịch bệnh: thuật toán này đã chứng minh vai trò quan trọng trong lĩnh vực y tế, đặc biệt trong chẩn đoán bệnh và phát hiện bất thường trong dữ liệu y khoa. Nhờ vào khả năng phân tích dữ liệu nhanh chóng, thuật toán này giúp các bệnh viện và tổ chức y tế phát hiện sớm các dấu hiệu bệnh, hỗ trợ bác sĩ đưa ra quyết định chính xác hơn. Ngoài ra, XGBoost còn được sử dụng để dự báo sự lây lan của dịch bệnh, trong đại dịch COVID-19, thuật toán này đã giúp các nhà khoa học phân tích dữ liệu dịch tễ và xây dựng mô hình dự đoán về sự phát triển của dịch bệnh theo từng khu vực, từ đó hỗ trợ chính phủ đưa ra các biện pháp phòng ngừa phù hợp.

4. Nhận diện hình ảnh, phân loại các đối tượng: thuật toán còn được sử dụng trong hệ thống giám sát giao thông và phân tích ảnh vệ tinh để theo dõi biến đổi môi trường. Các công ty như Apple, Facebook và Google đã ứng dụng XGBoost để cải thiện thuật toán nhận diện khuôn mặt, nâng cao trải nghiệm người dùng và bảo mật dữ liệu.

5. Dự báo giao thông và tối ưu hóa vận hành đô thị: XGBoost đóng vai trò quan trọng trong dự đoán lưu lượng giao thông, tối ưu hóa hệ thống đèn tín hiệu và hỗ trợ xe tự hành. Bằng cách phân tích dữ liệu từ cảm biến giao thông, GPS và camera giám sát, thuật toán giúp dự báo tắc nghẽn, cho phép điều phối giao thông hiệu quả hơn. Ngoài ra, XGBoost còn hỗ trợ hệ thống vận tải công cộng tối ưu hóa tuyến xe buýt và tàu điện, giúp giảm thời gian di chuyển và tiết kiệm năng lượng. Google Maps, Singapore và New

York đã triển khai XGBoost trong hệ thống giao thông thông minh, giúp giảm thiểu ùn tắc và cải thiện chất lượng di chuyển đô thị.

Trong “Tập chí Khoa học Đại học Thủ Dầu Một”, Dương Thị Kim Chi đã áp dụng thuật toán XGBoost để tạo nên mô hình chẩn đoán bệnh Covid-19 từ dữ liệu lâm sàng, tức là từ các mẫu xét nghiệm của các nạn nhân. Mô hình sẽ giúp giảm thiểu các chi phí phát sinh trong quá trình khám và chữa bệnh, cũng như là giảm áp lực về thời gian trả kết quả xét nghiệm của các bệnh nhân Covid-19.

Trong nghiên cứu "Parkinson's Disease Detection using XGBoost and Machine Learning" của Dheiver Francisco Santos, tác giả đã áp dụng thuật toán XGBoost để xây dựng mô hình phát hiện sớm bệnh Parkinson từ dữ liệu âm thanh và tần số giọng nói. Mô hình đạt độ chính xác 93.33%, với Precision 91.67% và Recall 95.65%, giúp phát hiện bệnh nhanh chóng và chính xác, góp phần hỗ trợ bác sĩ trong chẩn đoán sớm, cải thiện hiệu quả điều trị và giảm thiểu rủi ro trong chăm sóc sức khỏe.

Trong nghiên cứu "The Power of Words: Predicting Stock Market Returns with Fine-Grained Sentiment Analysis and XGBoost" của Farshid Balaneji, Dietmar Maringer và Irena Spasic, các tác giả đã áp dụng thuật toán XGBoost kết hợp với phân tích cảm xúc chi tiết để dự đoán lợi nhuận thị trường chứng khoán. Mô hình được tối ưu hóa bằng tối ưu hóa siêu tham số Bayesian và kiểm tra bằng phương pháp cross-validation lồng nhau. Kết quả cho thấy mức độ ảnh hưởng của cảm xúc trong tin tức không đồng đều giữa các ngành, trong đó ngành dầu mỏ phản ứng mạnh mẽ nhất với các chỉ số cảm xúc. Nghiên cứu nhấn mạnh tầm quan trọng của việc sử dụng các biện pháp cảm xúc chi tiết để đưa ra quyết định chính xác về hướng đi của thị trường, đặc biệt là trong ngành dầu mỏ.

Trong nghiên cứu "Mô phỏng nồng độ bụi PM2.5 tại khu vực trung tâm Thành phố Hồ Chí Minh bằng thuật toán học máy và học sâu" của Nguyễn Phúc Hiếu, Nguyễn Nhật Dương, Đỗ Quang Lĩnh, Đào Nguyên Khôi, các tác giả đã sử dụng thuật toán XGBoost Regression (XGBR) để mô phỏng nồng độ bụi PM2.5 từ dữ liệu khí tượng. Thuật toán XGBoost cho thấy hiệu quả mô phỏng cao nhất khi sử dụng đủ 6 thông số đầu vào (nhiệt độ, tốc độ gió, số giờ nắng, độ ẩm, hướng gió và lượng mưa), với các chỉ số đạt được gồm hệ số tương quan $r = 0,854$, chỉ số tương đồng IOA = 0,922 và độ lệch

trung bình chuẩn hóa $NMB = 6,711$. Kết quả này cho thấy XGBoost là phương pháp hiệu quả và đáng tin cậy nhất trong việc mô phỏng nồng độ bụi $PM_{2.5}$ tại trung tâm TP.HCM, giúp hỗ trợ các nhà quản lý và chuyên gia trong công tác kiểm soát và dự báo ô nhiễm không khí.

2.1.2. Học tăng cường (Boosting)

Boosting là một phương pháp trong học máy được thiết kế nhằm giảm thiểu lỗi trong phân tích dữ liệu dự đoán. Kỹ thuật này giúp tăng cường độ chính xác của các mô hình bằng cách kết hợp nhiều mô hình yếu (weak learners) lại với nhau thành một mô hình mạnh (strong learner). Boosting ban đầu được giới thiệu bởi Yoav Freund và Robert Schapire vào năm 1997 với thuật toán AdaBoost, nhằm mục đích tăng cường độ chính xác của mô hình phân loại. Thuật toán Gradient Boosting được phát triển sau đó bởi Jerome H. Friedman vào năm 1999, nhằm cải thiện hiệu suất cho các bài toán hồi quy và phân loại.

Trong học máy, các nhà khoa học dữ liệu đào tạo mô hình dự báo trên tập dữ liệu đã được gắn nhãn (labeled data) để tạo ra các dự đoán cho tập dữ liệu chưa được gắn nhãn (unlabeled data). Tuy nhiên, một mô hình duy nhất có thể mắc lỗi dự đoán nếu chất lượng dữ liệu huấn luyện không đủ cao. Ví dụ, nếu một mô hình nhận diện mèo chỉ được huấn luyện với các hình ảnh mèo trắng, nó có thể nhầm lẫn một con mèo đen với một đối tượng khác. Boosting cố gắng khắc phục nhược điểm này bằng cách huấn luyện một chuỗi các mô hình nhỏ theo trình tự. Mỗi mô hình trong chuỗi sẽ tập trung vào việc sửa lỗi của mô hình trước đó, từ đó cải thiện độ chính xác của hệ thống tổng thể. Việc kết hợp nhiều mô hình theo cách này giúp tăng cường độ chính xác, giảm thiểu lỗi dự đoán, và tạo ra một mô hình dự báo mạnh mẽ hơn. XGBoost được giới thiệu lần đầu như một phiên bản tăng cường của Gradient Boosting, tập trung vào việc tối ưu hóa tốc độ và hiệu quả. Một số ý nghĩa mà nó mang lại:

+ Boosting là một trong những kỹ thuật học máy mạnh mẽ và được sử dụng rộng rãi trong nhiều lĩnh vực phân tích dữ liệu dự đoán. Ý nghĩa của phương pháp này nằm ở khả năng tăng cường độ chính xác của mô hình học máy bằng cách kết hợp nhiều mô hình yếu (weak learners) thành một mô hình mạnh (strong learner).

+ Thuật toán hoạt động dựa trên nguyên lý học tuần tự. Mỗi mô hình trong chuỗi sẽ học từ lỗi của mô hình trước, tập trung vào các mẫu khó dự đoán hoặc bị sai sót nhiều. Nhờ vậy, mô hình sau luôn tốt hơn mô hình trước, giúp cải thiện kết quả dự đoán một cách rõ rệt.

+ Cách tiếp cận này không chỉ giúp nâng cao độ chính xác mà còn tối ưu hóa hiệu suất mô hình. Điều này đặc biệt quan trọng trong các bài toán phức tạp như dự báo tài chính, nhận diện hình ảnh, hay phát hiện gian lận.

+ Điểm hạn chế của mô hình này là dễ bị overfitting nếu mô hình được huấn luyện quá kỹ trên tập dữ liệu nhiều. Bên cạnh đó, quá trình huấn luyện phức tạp và tốn nhiều thời gian, nhất là với các tập dữ liệu lớn. Để khắc phục vấn đề này, các biến thể như XGBoost, AdaBoost, và Gradient Boosting đã ra đời nhằm tối ưu hóa tốc độ huấn luyện và cải thiện độ chính xác.

Đã có rất nhiều nghiên cứu về việc áp dụng các phương pháp học máy trong việc lập bản đồ lớp phủ bề mặt trên toàn cầu, trong đó có nhiều ứng dụng tại Việt Nam. Một ví dụ điển hình là nghiên cứu của Trần Văn Anh, Nguyễn Ngọc Hiền, Trần Văn Trường và Đỗ Phước Đức (2023), trong đó sử dụng dữ liệu vệ tinh Sentinel-2 kết hợp với nền tảng Google Earth Engine (GEE) để xây dựng bản đồ lớp phủ bề mặt tỉnh Cà Mau. Nghiên cứu này đã sử dụng các thuật toán học máy phổ biến như Random Forest (RF), Máy vector hỗ trợ (SVM) và Gradient Boosting (GBoost) nhằm phân loại các đối tượng lớp phủ khác nhau. Kết quả của nghiên cứu cho thấy phương pháp Random Forest đạt độ chính xác cao nhất với OA = 86,5% và hệ số Kappa = 0,81, vượt trội hơn so với hai phương pháp còn lại là SVM (OA = 79,5%, Kappa = 0,72) và GBoost (OA = 85,6%, Kappa = 0,79). Điều này chứng minh rằng RF là thuật toán hiệu quả nhất trong việc phân loại lớp phủ bề mặt tỉnh Cà Mau.

Một ví dụ khác là nghiên cứu của Nguyễn Văn Bình và cộng sự (2022), trong đó tập trung vào việc so sánh hiệu quả của các thuật toán học máy trong dự báo biến động lớp phủ bề mặt đô thị tại TP.HCM. Nghiên cứu này đã chứng minh rằng phương pháp Gradient Boosting mang lại kết quả tương đối tốt nhưng vẫn không vượt qua được Random Forest về độ chính xác. Các nghiên cứu trên cho thấy việc áp dụng các thuật toán học máy như RF, SVM và GBoost trên nền tảng Google Earth Engine có tiềm năng

lớn trong việc lập bản đồ lớp phủ bề mặt. Trong đó, phương pháp Random Forest nổi bật với khả năng xử lý dữ liệu hiệu quả và độ chính xác cao, góp phần nâng cao chất lượng và độ tin cậy của các bản đồ lớp phủ bề mặt.

2.1.3. Các chỉ số rủi ro tài chính:

1. Value at Risk (VaR)

Value at Risk (VaR) là một chỉ số tài chính được sử dụng rộng rãi để đo lường mức độ rủi ro của danh mục đầu tư. Chỉ số này ước tính mức lỗ tối đa có thể xảy ra trong một khoảng thời gian nhất định với một mức độ tin cậy cụ thể (thường là 95% hoặc 99%).

$$VaR = \mu - Z \times \sigma$$

Trong đó:

+ μ : Trung bình lợi nhuận.

+ σ : Độ lệch chuẩn của lợi nhuận.

+ Z : Điểm tới hạn từ phân phối chuẩn (ví dụ: 1.65 cho 95% hoặc 2.33 cho 99%)

Được dùng để trả lời cho câu hỏi: “Trong trường hợp xấu nhất, tôi có thể mất bao nhiêu với độ tin cậy 95% trong 1 ngày?”. Ví dụ: Nếu $VaR(5\%) = -0.023$, điều đó có nghĩa là: Có 95% khả năng mức lỗ không vượt quá 2.3% trong khoảng thời gian nhất định. Có 5% khả năng mức lỗ sẽ lớn hơn 2.3%.

2. Expected Shortfall (ES)

Expected Shortfall (ES), còn được gọi là Conditional Value at Risk (CVaR), là một chỉ số tài chính đo lường mức lỗ trung bình trong các tình huống tồi tệ nhất, tức là các trường hợp vượt quá ngưỡng VaR. Khác với VaR chỉ tập trung vào ngưỡng lỗ tối đa có thể xảy ra với một độ tin cậy nhất định, ES tập trung vào mức lỗ kỳ vọng trong các tình huống cực đoan. ES được coi là một công cụ quản lý rủi ro hiệu quả hơn so với VaR vì nó cung cấp thông tin về mức độ thiệt hại khi xảy ra sự kiện rủi ro lớn.

$$ES = E(X|X \leq VaR)$$

Trong đó:

+ $E(X)$: Kỳ vọng của tổn thất.

+ $X \leq VaR$: Điều kiện tổn thất vượt qua VaR.

3. Cumulative Profit and Loss (PnL)

Đây là chỉ số đánh giá hiệu quả đầu tư bằng cách tính toán tổng lợi nhuận hoặc thua lỗ tích lũy trong một khoảng thời gian nhất định. Ý nghĩa của PnL là cung cấp cho nhà đầu tư cái nhìn về mức độ sinh lợi hoặc thua lỗ của danh mục, từ đó giúp so sánh và đánh giá hiệu quả của các chiến lược đầu tư khác nhau.

$$PnL = \frac{\text{Giá cuối} - \text{giá đầu}}{\text{Giá đầu}}$$

- Trong đó:

+ Giá cuối: Giá trị tài sản tại thời điểm kết thúc.

+ Giá đầu: Giá trị tài sản tại thời điểm bắt đầu.

4. Maximum Drawdown (MDD)

Maximum Drawdown (MDD) là chỉ số đo lường mức suy giảm tối đa từ đỉnh đến đáy của danh mục đầu tư trong một khoảng thời gian. MDD cho biết mức lỗ lớn nhất mà nhà đầu tư phải chịu trước khi danh mục phục hồi trở lại. Ý nghĩa của MDD là giúp nhà đầu tư hiểu rõ hơn về khả năng chống chịu rủi ro và tính ổn định của chiến lược đầu tư, từ đó đánh giá mức độ an toàn của danh mục trong các giai đoạn biến động.

$$MDD = \frac{\text{Đỉnh cao nhất} - \text{Đáy thấp nhất}}{\text{Đáy thấp nhất}}$$

- Trong đó:

+ Đỉnh cao nhất: Giá trị tài sản tại thời điểm cao nhất.

+ Đáy thấp nhất: Giá trị tài sản tại thời điểm thấp nhất sau khi đạt đỉnh.

5. Log - Return

Log-return là một trong những phương pháp tính toán tỷ suất sinh lợi được sử dụng phổ biến trong phân tích tài chính. Thay vì sử dụng tỷ suất sinh lợi thông thường (simple return), log-return giúp giảm thiểu tác động của các biến động mạnh và đảm bảo tính ổn định trong mô hình dự báo.

$$R = \text{Log}\left(\frac{P_t}{P_{t-1}}\right)$$

- Trong đó:

+ R: Log-return tại thời điểm t.

+ P_t : Giá trị tài sản tại thời điểm t.

+ P_{t-1} : Giá trị tài sản tại thời điểm trước đó.

+ Log: Hàm logarit tự nhiên (cơ số e).

2.1.4. Các mô hình dự báo tài chính liên quan

Trong lĩnh vực tài chính, có nhiều mô hình dự báo được sử dụng để phân tích và dự đoán xu hướng thị trường, trong đó có một số mô hình phổ biến và liên quan đến XGBoost được sử dụng rộng rãi trong dự báo tài chính.

- Random Forest (RF) là một thuật toán học máy thuộc nhóm ensemble learning, kết hợp nhiều cây quyết định để tạo thành một mô hình mạnh hơn. Các cây trong rừng được huấn luyện độc lập với các mẫu dữ liệu khác nhau, sau đó kết quả được tổng hợp lại bằng trung bình (đối với hồi quy) hoặc bỏ phiếu đa số (đối với phân loại). Dự báo của mô hình Random Forest là tổng hợp đầu ra từ nhiều cây, trong đó mỗi cây đóng góp một phần kết quả vào dự báo cuối cùng. Công thức tổng quát của Random Forest là:

$$f(x) = \frac{1}{B} \sum_{b=1}^B T_b(x)$$

Trong đó: + B là số lượng cây trong rừng.

+ $T_b(x)$ là đầu ra của cây thứ b khi dự đoán giá trị x .

Mô hình này có độ chính xác cao nhờ tổng hợp nhiều mô hình và không dễ bị overfitting do tính trung bình hóa, đồng thời xử lý tốt với dữ liệu lớn và có nhiều biến. Tuy nhiên, mô hình này lại có nhược điểm là khó diễn giải do kết hợp nhiều cây quyết định, và độ phức tạp tính toán cao nếu số lượng cây lớn. Random Forest thường được ứng dụng trong các bài toán dự báo giá cổ phiếu, phát hiện gian lận trong giao dịch và phân loại rủi ro tín dụng.

- Gradient Boosting Machine (GBM) là một kỹ thuật học máy tăng cường (boosting) sử dụng nhiều mô hình yếu (thường là cây quyết định) để tạo ra một mô hình mạnh hơn. Các mô hình được xây dựng tuần tự, với mỗi mô hình sau cố gắng sửa lỗi của mô hình trước đó bằng cách tối thiểu hóa hàm mất mát. Dự báo của mô hình là tổng của các cây quyết định với trọng số của từng cây được điều chỉnh dựa trên độ chính xác của cây trước. Công thức tổng quát của GBM là:

$$\hat{y} = \sum_{m=1}^M \gamma_m h_m(x)$$

Trong đó: + M là số lượng cây.

+ $h_m(x)$ là kết quả từ mô hình thứ m ;

+ γ_m là trọng số của mô hình thứ m ;

GBM mang lại độ chính xác cao trong các bài toán phức tạp, xử lý dữ liệu phi tuyến tính tốt và tối ưu hóa hiệu suất bằng cách giảm thiểu hàm mất mát. Tuy nhiên, mô hình này dễ bị overfitting nếu không điều chỉnh siêu tham số hợp lý và có thời gian huấn luyện lâu khi số lượng cây lớn. GBM thường được áp dụng trong các bài toán dự báo giá trị bất động sản, dự đoán lợi nhuận doanh nghiệp và phân tích tín dụng.

- LightGBM (Light Gradient Boosting Machine) là một biến thể của Gradient Boosting, được phát triển nhằm tăng tốc độ huấn luyện và giảm tiêu thụ bộ nhớ.

LightGBM sử dụng kỹ thuật leaf-wise tree growth thay vì level-wise, giúp mô hình đạt được hiệu quả cao hơn trong quá trình huấn luyện. Dự báo của LightGBM có thể được biểu diễn tương tự như GBM:

$$\hat{y} = \sum_{m=1}^M \gamma_m h_m(x)$$

Điểm khác biệt nằm ở cách thức xây dựng cây: trong khi GBM sử dụng level-wise (phát triển đều theo từng mức), LightGBM sử dụng leaf-wise (phát triển theo hướng tối ưu hóa từng lá), giúp giảm thiểu thời gian huấn luyện và bộ nhớ sử dụng. LightGBM có tốc độ huấn luyện nhanh hơn nhờ khả năng xử lý song song tốt, phù hợp với dữ liệu lớn và dữ liệu có nhiều tính năng. Đồng thời, mô hình này cũng giảm thiểu bộ nhớ sử dụng nhờ phương pháp histogram-based. Tuy nhiên, LightGBM dễ bị overfitting khi số lượng lá quá lớn và không hiệu quả với dữ liệu nhỏ hoặc thiếu cân bằng. LightGBM thường được sử dụng trong các bài toán dự báo tài chính, phân tích rủi ro tín dụng và dự đoán doanh số bán hàng.

- CatBoost (Categorical Boosting) là một thuật toán boosting đặc biệt, được thiết kế để xử lý trực tiếp dữ liệu dạng danh mục mà không cần chuyển đổi thủ công. Thuật toán này sử dụng kỹ thuật ordered boosting để tránh lỗi tiên đoán (prediction shift), từ đó giúp nâng cao độ chính xác của mô hình. Mô hình CatBoost cũng được biểu diễn tương tự như GBM:

$$\hat{y} = \sum_{m=1}^M \gamma_m h_m(x)$$

Điểm khác biệt là CatBoost xử lý dữ liệu danh mục mà không cần mã hóa trước (one-hot encoding), đồng thời ít bị overfitting nhờ vào kỹ thuật ordered boosting. Tuy nhiên, tốc độ huấn luyện của CatBoost chậm hơn so với LightGBM, đặc biệt khi làm việc với tập dữ liệu lớn, và việc cài đặt cũng như tinh chỉnh phức tạp hơn so với các mô hình khác. CatBoost thường được ứng dụng trong các bài toán dự báo tài chính, phân tích khách hàng trong thương mại điện tử và phân loại trong lĩnh vực y tế.

Trong các mô hình dự báo tài chính, mỗi phương pháp đều có ưu và nhược điểm riêng. Random Forest mạnh trong việc tránh overfitting và xử lý dữ liệu lớn, GBM mang lại độ chính xác cao nhưng dễ bị quá khớp, LightGBM tối ưu hóa tốc độ và hiệu suất với tập dữ liệu lớn, trong khi CatBoost lại vượt trội khi làm việc với dữ liệu danh mục. Việc lựa chọn mô hình phù hợp phụ thuộc vào đặc điểm dữ liệu, mục tiêu dự báo và khả năng tính toán. Trong bối cảnh hiện nay, XGBoost vẫn là lựa chọn hàng đầu nhờ khả năng kết hợp giữa tính linh hoạt và độ chính xác cao, đồng thời giảm thiểu các hạn chế của các mô hình boosting truyền thống.

2.1.5. XGBoost trong dự báo chuỗi thời gian và tài chính:

XGBoost là một trong những mô hình học máy mạnh mẽ và được sử dụng rộng rãi trong các bài toán dự báo chuỗi thời gian tài chính. Đặc điểm nổi bật của các chuỗi thời gian tài chính là tính bất ổn định, phi tuyến và chịu ảnh hưởng bởi nhiều yếu tố kinh tế xã hội. Vì vậy, việc dự báo các biến động giá cổ phiếu, lợi nhuận quỹ đầu tư hay các chỉ số kinh tế trở nên phức tạp hơn rất nhiều so với việc sử dụng các mô hình hồi quy tuyến tính truyền thống như ARIMA.

Trong mô hình dự báo tài chính, XGBoost được sử dụng để dự báo giá của các đồng coin dựa trên các yếu tố đầu vào như log-return, khối lượng giao dịch, giá đóng cửa, giá mở cửa và các yếu tố kỹ thuật khác. Mô hình này áp dụng các kỹ thuật tăng cường độ chính xác thông qua quá trình xây dựng nhiều cây quyết định tuần tự, trong đó mỗi cây sau tập trung sửa lỗi của cây trước đó. Điều này giúp XGBoost có khả năng học sâu từ các mẫu dữ liệu phức tạp, đồng thời khắc phục được những hạn chế của các mô hình dự báo tuyến tính.

Một lợi thế quan trọng của XGBoost trong dự báo chuỗi thời gian là khả năng xử lý các yếu tố phi tuyến và tối ưu hóa tốc độ huấn luyện thông qua các kỹ thuật tính toán song song và tối ưu hóa bộ nhớ. So với các mô hình như LightGBM hay CatBoost, XGBoost nổi bật hơn nhờ khả năng tự động điều chỉnh siêu tham số và xử lý dữ liệu thiếu một cách hiệu quả. Điều này giúp mô hình hoạt động tốt ngay cả khi dữ liệu đầu vào không hoàn chỉnh hoặc không đồng nhất, một đặc điểm thường gặp trong dự báo tài chính.

XGBoost cũng cho phép xử lý dữ liệu trễ và không đồng nhất một cách linh hoạt nhờ khả năng sử dụng các hàm mất mát khác nhau như hàm mất mát tuyến tính, hàm mất mát phi tuyến hoặc các hàm mất mát tùy chỉnh. Điều này giúp mô hình đạt được độ chính xác cao hơn so với các phương pháp truyền thống.

Một điểm mạnh khác của XGBoost là khả năng tối ưu hóa cấu trúc cây thông qua kỹ thuật pruning và regularization. Điều này giúp mô hình tránh được hiện tượng overfitting, vốn là một thách thức lớn trong dự báo chuỗi thời gian tài chính khi dữ liệu có biến động mạnh.

Nhờ vào những đặc điểm ưu việt này, XGBoost đã được ứng dụng rộng rãi trong việc dự báo giá coin, dự báo giá cổ phiếu, dự báo lợi nhuận quỹ đầu tư và thậm chí là dự báo các chỉ số kinh tế vĩ mô. Các tổ chức tài chính lớn và các quỹ đầu tư sử dụng XGBoost để phân tích và dự báo các biến động giá, từ đó đưa ra các quyết định đầu tư phù hợp và tối ưu hóa danh mục đầu tư của họ. Việc áp dụng XGBoost trong dự báo chuỗi thời gian tài chính không chỉ giúp nâng cao độ chính xác mà còn giảm thiểu sai số dự báo, từ đó mang lại giá trị thực tiễn cao trong các quyết định đầu tư và phân tích thị trường tài chính.

Tổng quát, XGBoost đã chứng minh được tính hiệu quả và độ chính xác cao trong việc dự báo chuỗi thời gian tài chính và phân tích biến động thị trường. Với khả năng xử lý dữ liệu phi tuyến và độ phức tạp cao, XGBoost vượt trội so với các mô hình truyền thống như ARIMA hay các mô hình ensemble khác như Random Forest và Gradient Boosting. Trong các nghiên cứu gần đây, XGBoost đã được sử dụng rộng rãi để dự báo các biến số tài chính như giá cổ phiếu, chỉ số kinh tế, tỷ giá hối đoái và lợi nhuận quỹ đầu tư. Bằng việc xây dựng mô hình học tăng cường qua từng bước lặp, XGBoost giúp tối ưu hóa dự đoán bằng cách học sâu từ các mẫu dữ liệu biến động mạnh, từ đó mang lại độ chính xác cao trong các dự báo chuỗi thời gian.

Tóm lại, XGBoost đã thể hiện khả năng dự báo hiệu quả trong các bài toán dự báo chuỗi thời gian tài chính với độ chính xác cao và khả năng xử lý tốt các yếu tố phi tuyến. Mô hình không chỉ giúp nhà đầu tư có được cái nhìn tổng quan về biến động giá trong tương lai mà còn giúp quản lý rủi ro thông qua việc phân tích các chỉ số rủi ro tài chính.

Dù còn một số thách thức trong việc tối ưu hóa và xử lý dữ liệu, XGBoost vẫn là một công cụ mạnh mẽ và hiệu quả cho các chiến lược dự báo và phân tích tài chính.

2.2. Phương pháp nghiên cứu:

2.2.1. Quy trình nghiên cứu:

Dưới đây là quy trình từng bước dự báo giá coin của nhóm chúng tôi được thực hiện. Các bước được xây dựng dựa trên nền tảng lý thuyết vững chắc kết hợp với các kỹ thuật phân tích và xử lý dữ liệu hiện đại nhằm đảm bảo tính chính xác và độ tin cậy cao trong quá trình dự báo, bao gồm:

1. Xác định vấn đề nghiên cứu: Đề tài tập trung vào dự báo giá coin với mô hình XGBoost, một trong những mô hình học máy mạnh mẽ nhất hiện nay trong lĩnh vực dự báo tài chính. Việc dự báo giá coin luôn là một thách thức lớn do tính chất biến động mạnh và khó dự đoán của thị trường tiền điện tử. Do đó, mục tiêu của nghiên cứu này là áp dụng mô hình XGBoost để dự báo giá coin trong 24 giờ tiếp theo, nhằm nâng cao độ chính xác và khả năng ra quyết định đầu tư. Việc áp dụng mô hình XGBoost giúp tận dụng tối đa khả năng học phi tuyến và tốc độ xử lý nhanh, giúp đối phó với những biến động phức tạp của thị trường tài chính.

2. Xác định lý thuyết nền: Nghiên cứu dựa trên nền tảng lý thuyết về mô hình XGBoost và lý thuyết log-return. XGBoost (eXtreme Gradient Boosting) là một thuật toán học máy thuộc nhóm Boosting, sử dụng các cây quyết định nhỏ (weak learners) để tạo thành một mô hình mạnh (strong learner) bằng cách kết hợp các mô hình yếu theo phương pháp giảm thiểu hàm mất mát qua nhiều vòng lặp. Đặc biệt, XGBoost nổi bật với khả năng tối ưu hóa siêu tham số, tính toán nhanh và khả năng khắc phục overfitting thông qua regularization. Log-return là một phép đo lường tỷ suất sinh lợi được sử dụng phổ biến trong phân tích tài chính, giúp làm mượt dữ liệu và đảm bảo tính ổn định trong dự báo. Việc sử dụng log-return thay vì giá trị trực tiếp giúp giảm thiểu sai số trong trường hợp biến động mạnh và làm tăng độ chính xác của mô hình dự báo.

3. Thu thập dữ liệu: Dữ liệu sử dụng trong nghiên cứu được thu thập từ các nguồn giao dịch tiền điện tử đáng tin cậy, bao gồm các thông số như giá mở cửa, giá đóng cửa,

giá cao nhất, giá thấp nhất và khối lượng giao dịch của ba loại coin trong khoảng thời gian dài.

4. Tiền xử lý dữ liệu: Làm sạch dữ liệu, xử lý ngoại lệ, loại bỏ các điểm nhiễu và chuẩn hóa dữ liệu. Tạo các đặc trưng kỹ thuật (feature engineering) để tăng cường khả năng học của mô hình.

5. Xây dựng mô hình: Xây dựng mô hình: Sử dụng XGBoost kết hợp với Multi Output Regression để dự báo đồng thời nhiều loại coin, thiết lập các siêu tham số tối ưu để đạt được độ chính xác cao nhất. Việc sử dụng XGBoost giúp mô hình tự động lựa chọn các đặc trưng quan trọng và tối ưu hóa quá trình huấn luyện, nhờ đó tăng cường khả năng dự báo trong môi trường biến động mạnh.

6. Đánh giá mô hình: Mô hình được đánh giá bằng cách sử dụng chỉ số MSE (Mean Squared Error) để đo lường độ chính xác. Ngoài ra, các chỉ số rủi ro như Value at Risk (VaR), Expected Shortfall (ES), Cumulative Profit and Loss (PnL) và Maximum Drawdown (MDD) cũng được tính toán để đánh giá mức độ rủi ro và hiệu quả đầu tư. Kết quả dự báo được so sánh với giá thực tế để kiểm tra độ chính xác và tính ổn định của mô hình. Biểu đồ so sánh giữa giá thực tế và giá dự báo của các coin được xây dựng để minh họa khả năng dự báo của mô hình.

7. Trình bày kết quả: Kết quả dự báo được trình bày dưới dạng biểu đồ trực quan, so sánh giữa giá dự báo và giá thực tế trong 24 giờ tiếp theo. Các phân tích về độ chệch, sai số và hiệu quả của mô hình được thảo luận để đưa ra đánh giá khách quan về khả năng ứng dụng của XGBoost trong dự báo tài chính. Đồng thời, việc phân tích độ chính xác giữa các loại coin cũng giúp xác định xem mô hình có khả năng tổng quát hóa tốt hay không.

8. Rút ra kết luận và đưa ra khuyến nghị: Đánh giá khả năng áp dụng của mô hình XGBoost trong dự báo tài chính và đề xuất các hướng nghiên cứu tiếp theo.

2.2.2. Xác định lý thuyết nền:

Trong nghiên cứu này, chúng tôi lựa chọn mô hình XGBoost làm công cụ dự báo giá coin, dựa trên khả năng học phi tuyến và tính linh hoạt trong việc tối ưu hóa siêu

tham số. XGBoost thuộc nhóm Boosting, sử dụng nhiều mô hình cây quyết định nhỏ (weak learners) để tạo thành một mô hình mạnh (strong learner). Việc áp dụng XGBoost trong dự báo giá coin giúp đảm bảo độ chính xác cao nhờ khả năng giảm thiểu sai số liên tục thông qua tối ưu hóa gradient.

XGBoost nổi bật với khả năng tăng tốc độ huấn luyện nhờ vào tính toán song song và khả năng tối ưu hóa siêu tham số như learning rate, max depth, và n_estimators. Mô hình này cũng tích hợp các kỹ thuật regularization để giảm thiểu hiện tượng overfitting, đồng thời xử lý tốt các bài toán dự báo tài chính có tính phi tuyến cao.

Để đảm bảo dữ liệu được xử lý một cách ổn định và nhất quán, chúng tôi sử dụng log-return thay vì giá trị trực tiếp. Log-return giúp làm mượt dữ liệu, giảm thiểu tác động của các biến động mạnh, từ đó tăng cường độ tin cậy của mô hình dự báo. Ngoài ra, chúng tôi sử dụng các chỉ số rủi ro tài chính để đánh giá mức độ an toàn và hiệu quả của mô hình dự báo, bao gồm VaR, ES, Pnl, MDD.

2.2.3. Thu thập dữ liệu:

Thu thập dữ liệu là một bước quan trọng trong nghiên cứu, đóng vai trò nền tảng cho quá trình xây dựng và huấn luyện mô hình dự báo. Dữ liệu được thu thập từ nhiều nguồn uy tín để đảm bảo độ tin cậy và tính toàn diện. Trong nghiên cứu này, dữ liệu được thu thập từ các sàn giao dịch tiền điện tử lớn như Binance, Coinbase và Bitfinex. Đây là những sàn giao dịch hàng đầu trên thế giới, cung cấp dữ liệu giao dịch với độ chính xác cao và độ trễ thấp. Các thông tin về giá coin được thu thập liên tục với tần suất hàng giờ, nhằm đảm bảo dữ liệu có độ phân giải cao và phản ánh đúng biến động của thị trường.

Các dữ liệu được thu thập bao gồm các thông số quan trọng như giá mở cửa (Open), giá đóng cửa (Close), giá cao nhất (High), giá thấp nhất (Low) và khối lượng giao dịch (Volume). Mỗi dữ liệu được thu thập trong một phiên giao dịch (thường là hàng giờ), đảm bảo mô hình có thể theo dõi được sự biến động của giá coin trong khoảng thời gian ngắn. Từ các giá trị này, log-return được tính toán để đo lường sự thay đổi tương đối của giá coin qua các phiên liên tiếp. Điều này giúp đảm bảo rằng mô hình có thể xử lý được các biến động mạnh và giảm thiểu ảnh hưởng của các giá trị cực đoan.

Dữ liệu được lưu trữ dưới định dạng Pickle (.pkl) để đảm bảo tính linh hoạt và hiệu quả trong việc đọc ghi dữ liệu với số lượng lớn. Định dạng Pickle giúp lưu trữ dữ liệu dưới dạng nhị phân, giảm thiểu thời gian tải và tiết kiệm bộ nhớ trong quá trình huấn luyện mô hình. Việc lưu trữ dữ liệu dưới dạng ma trận numpy giúp tối ưu hóa tốc độ xử lý và tích hợp tốt với các thư viện học máy như scikit-learn và XGBoost.

Sau khi thu thập dữ liệu, quá trình tiền xử lý được thực hiện nhằm đảm bảo chất lượng và độ chính xác của tập dữ liệu. Dữ liệu ban đầu có thể chứa nhiều nhiễu và điểm ngoại lệ (outliers), gây ảnh hưởng đến độ chính xác của mô hình dự báo. Do đó, bước làm sạch dữ liệu là rất quan trọng, bao gồm việc loại bỏ các bản ghi lỗi, xử lý các giá trị thiếu và chuẩn hóa dữ liệu để đảm bảo rằng tất cả các biến đều nằm trong cùng một thang đo. Các phương pháp xử lý ngoại lệ như Interquartile Range (IQR) và Z-score được áp dụng để phát hiện và loại bỏ các giá trị bất thường.

Sau khi làm sạch, dữ liệu được chuyển đổi sang định dạng phù hợp để sử dụng trong mô hình XGBoost. Log-return được tính toán từ sự biến động của giá qua từng phiên giao dịch theo công thức:

$$R = \text{Log}\left(\frac{P_t}{P_{t-1}}\right)$$

Với P_t là giá tại thời điểm t và P_{t-1} là giá tại thời điểm trước đó. Log-return giúp làm mượt dữ liệu, giảm thiểu tác động của các biến động mạnh và đảm bảo tính ổn định trong dự báo. Dữ liệu sau khi được xử lý sẽ được chia thành hai tập: tập huấn luyện (Train) và tập kiểm tra (Test) với tỷ lệ 80-20. Việc chia tập dữ liệu như vậy giúp mô hình học từ quá khứ và kiểm tra khả năng dự báo trên các dữ liệu chưa từng thấy. Quá trình chia được thực hiện theo thứ tự thời gian để đảm bảo rằng mô hình không bị ảnh hưởng bởi dữ liệu tương lai trong quá trình huấn luyện, từ đó tránh hiện tượng rò rỉ dữ liệu. Để đảm bảo chất lượng của tập dữ liệu huấn luyện và kiểm tra, chúng tôi tiến hành phân tích thống kê sau quá trình tiền xử lý nhằm kiểm tra xem dữ liệu đã được làm sạch và chuẩn hóa đúng cách hay chưa. Điều này giúp mô hình không bị nhiễu do các biến động bất thường hoặc do dữ liệu không nhất quán.

Như vậy, quá trình thu thập và xử lý dữ liệu đóng vai trò quan trọng trong việc đảm bảo mô hình XGBoost có khả năng dự báo chính xác. Việc thu thập từ các nguồn uy tín, làm sạch dữ liệu kỹ lưỡng và chia tập dữ liệu hợp lý là những bước cần thiết để tối ưu hóa hiệu quả của mô hình và giảm thiểu rủi ro trong quá trình dự báo.

2.2.4. Xây dựng mô hình:

Trong nghiên cứu này, chúng tôi sử dụng mô hình XGBoost làm công cụ dự báo giá coin, do khả năng học phi tuyến mạnh mẽ và tốc độ xử lý nhanh. XGBoost là một trong những mô hình Boosting tiên tiến nhất hiện nay, sử dụng nhiều mô hình cây quyết định nhỏ (weak learners) để tạo thành một mô hình mạnh (strong learner). Điều này giúp mô hình có khả năng giảm thiểu sai số và tối ưu hóa hiệu quả dự báo. XGBoost được phát triển với khả năng tăng tốc độ huấn luyện nhờ vào tính toán song song và khả năng tối ưu hóa siêu tham số như learning rate, max depth, và n_estimators. Mô hình này cũng tích hợp các kỹ thuật regularization để giảm thiểu hiện tượng overfitting, đồng thời xử lý tốt các bài toán dự báo tài chính có tính phi tuyến cao.

Một trong những điểm nổi bật của nghiên cứu này là việc sử dụng log-return giúp làm mượt dữ liệu, giảm thiểu tác động của các biến động mạnh và đảm bảo tính ổn định trong dự báo. Điều này giúp mô hình dự báo chính xác hơn, đặc biệt là trong các khoảng thời gian có sự biến động mạnh về giá.

Việc xử lý dữ liệu là bước rất quan trọng để đảm bảo độ chính xác và ổn định của mô hình. Dữ liệu được thu thập từ các nguồn uy tín, sau đó tiến hành tiền xử lý để loại bỏ nhiễu và chuẩn hóa dữ liệu. Các bước xử lý dữ liệu bao gồm:

1. Làm sạch dữ liệu: Dữ liệu được kiểm tra để phát hiện các giá trị bị thiếu hoặc ngoại lệ. Các bản ghi bị lỗi hoặc chứa giá trị không hợp lệ sẽ được loại bỏ để tránh làm sai lệch kết quả dự báo. Các kỹ thuật như IQR (Interquartile Range) và Z-score được sử dụng để phát hiện và xử lý ngoại lệ.

2. Điền khuyết dữ liệu: Các khoảng trống trong dữ liệu được xử lý bằng cách sử dụng nội suy tuyến tính hoặc giá trị trung bình để điền vào. Điều này đảm bảo tính liên tục và nhất quán của chuỗi dữ liệu.

3. Chuẩn hóa dữ liệu: Để tránh hiện tượng một số biến có thang đo lớn chi phối mô hình, chúng tôi tiến hành chuẩn hóa dữ liệu về cùng một thang đo bằng cách sử dụng Min-Max Scaling hoặc Standard Scaling. Điều này giúp các biến có độ lớn tương đồng, đảm bảo quá trình huấn luyện diễn ra ổn định.

4. Tạo đặc trưng (Feature Engineering): Sau khi chuẩn hóa, dữ liệu được tổ chức thành các cửa sổ trượt (rolling windows) với kích thước 24 mẫu để tạo ra các tập dữ liệu con, giúp mô hình học được các xu hướng biến động theo từng khoảng thời gian. Các cửa sổ dữ liệu này được chuyển đổi thành các vector có kích thước 72 chiều (24×3) để đưa vào mô hình huấn luyện.

5. Chia tập huấn luyện và kiểm tra: Dữ liệu sau khi làm sạch và chuẩn hóa được chia thành hai tập: tập huấn luyện (80%) và tập kiểm tra (20%) để đảm bảo tính thời gian cho dữ liệu và tránh data leakage (dữ liệu nhìn trước tương lai). Tỷ lệ này đảm bảo rằng mô hình được học từ phần lớn dữ liệu nhưng vẫn còn đủ lượng dữ liệu để kiểm tra độ chính xác.

6. Lưu trữ dữ liệu đã xử lý: Sau khi hoàn tất các bước xử lý, dữ liệu được lưu trữ dưới định dạng Pickle (.pkl) để dễ dàng sử dụng trong quá trình huấn luyện và kiểm tra mô hình. Việc lưu trữ dưới dạng nhị phân giúp tăng tốc độ đọc/ghi và giảm thiểu dung lượng lưu trữ.

Việc xây dựng mô hình XGBoost là một bước trọng yếu trong quá trình nghiên cứu dự báo giá coin, bởi lẽ XGBoost được biết đến là một trong những thuật toán học máy mạnh mẽ nhất trong việc xử lý các bài toán hồi quy phi tuyến và dự báo tài chính. Mô hình XGBoost kết hợp các mô hình cây quyết định (Decision Trees) với kỹ thuật Boosting, giúp tăng cường độ chính xác dự báo thông qua việc giảm thiểu sai số theo từng bước lặp. Triển khai mô hình XGBoost trong nghiên cứu này được thiết lập với các tham số tối ưu như:

+ $N_estimators = 100$: Số lượng cây quyết định trong quá trình Boosting.

+ $Learning_rate = 0.1$: Tốc độ học, quyết định mức độ điều chỉnh trong quá trình tối ưu hóa.

+ Max_depth = 6: Độ sâu tối đa của mỗi cây, giúp kiểm soát độ phức tạp và tránh overfitting.

+ Objective='reg: squarederror': Hàm mất mát để đo lường sai số bình phương (MSE).

+ Random_state = 42: Thiết lập hạt giống để đảm bảo tính nhất quán trong quá trình chạy lại mô hình.

Trong bài toán dự báo giá coin, chúng tôi phải dự báo đồng thời giá của ba loại coin khác nhau. Do đó, để mô hình hóa đồng thời nhiều biến phụ thuộc, chúng tôi sử dụng Multi Output Regression kết hợp với XGBoost. MultiOutputRegressor là một kỹ thuật cho phép huấn luyện nhiều mô hình hồi quy một cách đồng thời, giúp mô hình dự đoán các biến đầu ra liên kết với nhau. Điều này giúp giảm thiểu độ lệch giữa các dự báo, đảm bảo tính nhất quán khi các đồng coin có mối tương quan với nhau.

2.2.4.1 Mô hình dự báo log-return với XGBoost

Mô hình XGBoost (eXtreme Gradient Boosting) là một phương pháp học máy mạnh mẽ, sử dụng tập hợp các cây quyết định nhỏ để tạo thành một mô hình mạnh. Mục tiêu của mô hình là dự báo log-return của từng đồng coin dựa trên các biến đầu vào là log-return quá khứ. Phương trình tổng quát của mô hình XGBoost được biểu diễn như sau:

$$\hat{R}_{t+1,j} = \sum_{m=1}^M \gamma_m h_m(X_{t,j})$$

Trong đó: + $\hat{R}_{t+1,j}$: Log-return dự báo của coin j tại thời điểm t+1;

+ M: Số lượng cây trong mô hình;

+ γ_m : Trọng số của cây quyết định thứ m;

+ $h_m(X_{t,j})$: Đầu ra từ mô hình cây thứ mmm với tập dữ liệu $(X_{t,j})$.

Mô hình XGBoost được lựa chọn vì khả năng dự báo chính xác và tốc độ huấn luyện nhanh, nhất là khi xử lý các bài toán có tính phi tuyến cao. Nhờ vào việc tối ưu hóa

gradient, XGBoost giúp giảm thiểu sai số và cải thiện hiệu suất dự báo trong môi trường dữ liệu tài chính có độ biến động lớn.

2.2.4.2 Mô hình chuyển đổi log-return sang giá

Sau khi dự báo được log-return, cần chuyển đổi chúng thành giá bằng cách tích lũy log-return theo thời gian. Phương trình chuyển đổi từ log-return sang giá được tính như sau:

$$P_{t+1,j} = P_{tj} \times e^{\hat{R}_{t+1,j}}$$

Trong đó: + $P_{t+1,j}$: Giá dự báo của coin j tại thời điểm $t+1$;

+ P_{tj} : Giá thực tế tại thời điểm t;

+ $\hat{R}_{t+1,j}$: Log-return dự báo tại thời điểm $t+1$.

Trong trường hợp dự báo cho 24 giờ liên tiếp, công thức chuyển đổi được mở rộng như sau:

$$P_{t+k,j} = P_{tj} \times \prod_{i=1}^k e^{\hat{R}_{t+i,j}}$$

Với k là số giờ liên tiếp (tối đa 24), và $\prod$ là phép nhân tích lũy của các log-return dự báo. Việc chuyển đổi từ log-return sang giá giúp dự báo trở nên trực quan hơn, dễ so sánh với giá thực tế. Điều này đảm bảo tính nhất quán và độ chính xác trong việc đánh giá hiệu quả của mô hình dự báo.

2.2.4.3 Mô hình MultiOutputRegressor

Mô hình MultiOutputRegressor được sử dụng để dự báo đồng thời nhiều biến phụ thuộc, trong trường hợp này là log-return của ba đồng coin. Phương trình tổng quát của mô hình này được biểu diễn như sau:

$$\begin{bmatrix} \widehat{R}_1 \\ \widehat{R}_2 \\ \widehat{R}_3 \end{bmatrix} = \sum_{m=1}^M \gamma_m \begin{bmatrix} h_{m1}(x) \\ h_{m2}(x) \\ h_{m3}(x) \end{bmatrix}$$

Trong đó: $+ \widehat{R}_1, \widehat{R}_2, \widehat{R}_3$: Dự báo log-return của ba đồng coin.

$+ h_{m1}(x), h_{m2}(x), h_{m3}(x)$: Đầu ra từ mô hình cây thứ m cho từng coin.

Việc sử dụng mô hình MultiOutputRegressor giúp mô hình hóa đồng thời nhiều biến đầu ra, tận dụng mối liên hệ giữa các coin trong dự báo. Điều này làm tăng khả năng tổng quát của mô hình và giảm thiểu sai số dự báo khi các đồng coin có mối tương quan chặt chẽ.

Các mô hình đã được phân tích chi tiết nhằm đảm bảo độ chính xác và tính hiệu quả trong dự báo giá coin. Việc sử dụng XGBoost kết hợp với MultiOutputRegressor giúp tối ưu hóa quá trình dự báo đồng thời nhiều coin, trong khi công thức chuyển đổi từ log-return sang giá đảm bảo sự nhất quán trong so sánh kết quả thực tế. Việc kết hợp các mô hình này giúp nâng cao khả năng dự báo và giảm thiểu sai số trong các biến động thị trường mạnh.

CHƯƠNG 3: KẾT QUẢ NGHIÊN CỨU

3.1. Giới thiệu

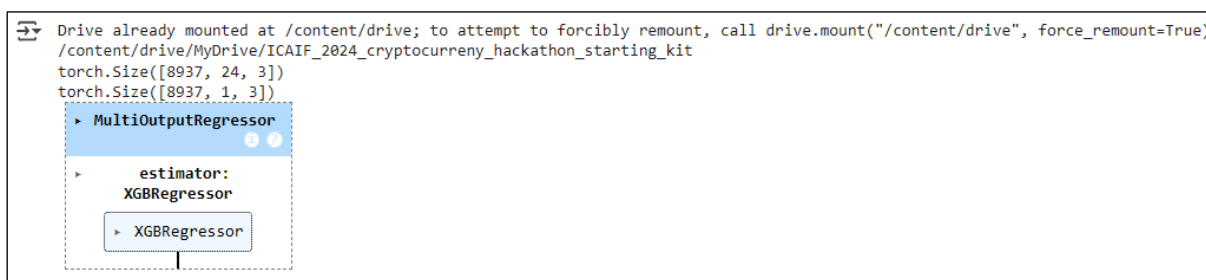
Trong bối cảnh thị trường tiền điện tử ngày càng phát triển và biến động mạnh, việc dự báo giá cả trở thành một trong những thách thức lớn đối với các nhà đầu tư và các tổ chức tài chính. Sự bất ổn của thị trường cùng với sự thay đổi không ngừng của các yếu tố tác động như khối lượng giao dịch, tâm lý thị trường và các yếu tố kinh tế vĩ mô đòi hỏi các mô hình dự báo phải có khả năng thích ứng và chính xác cao.

Trong báo cáo này, chúng tôi trình bày quy trình xây dựng mô hình dự báo giá tiền điện tử bằng cách sử dụng các thuật toán học máy tiên tiến. Mô hình chính được áp dụng là XGBoost Regressor kết hợp với MultiOutputRegressor nhằm tối ưu hóa dự báo đa biến đồng thời cho ba loại tiền điện tử. Mục tiêu của nghiên cứu là dự báo giá của các loại coin trong 24 giờ tiếp theo dựa trên chuỗi log-return đã thu thập được.

3.2. Phương pháp luận

3.2.1. Dữ liệu

Dữ liệu được sử dụng trong nghiên cứu được thu thập từ nhiều nguồn uy tín và được xử lý để đảm bảo tính chính xác.



Hình 3.2.1. Bộ dữ liệu đầu vào

Các dữ liệu chính bao gồm:

- + Log-return: Mảng log-return có kích thước (8937, 24, 3), biểu diễn sự thay đổi giá của ba loại coin trong khoảng thời gian 24 giờ.

- + Giá khởi đầu: Mảng giá khởi đầu có kích thước (8937, 1, 3), biểu thị giá tại thời điểm bắt đầu của mỗi chuỗi thời gian.

Dữ liệu được kiểm tra để đảm bảo sự nhất quán và không có lỗi thiếu hoặc giá trị bất thường. Đối với mỗi loại tiền điện tử, log-return được chuyển đổi thành giá dự báo bằng cách tính tích lũy log-return để đảm bảo độ chính xác khi chuyển đổi từ mức thay đổi giá sang giá thực.

3.2.2. Mô hình dự báo

Mô hình được lựa chọn là XGBoost Regressor, một thuật toán mạnh mẽ trong việc xử lý các bài toán hồi quy và phân loại. Để dự báo đồng thời cho cả ba coin, chúng tôi sử dụng MultiOutputRegressor nhằm đảm bảo khả năng dự báo đa biến.

Mô hình sử dụng các siêu tham số được tối ưu hóa như sau:

- + `n_estimators`: 100 - Số lượng cây trong mô hình boosting.
- + `learning_rate`: 0.1 - Tốc độ học, giúp cân bằng giữa việc học quá mức và học thiếu.
- + `max_depth`: 6 - Độ sâu của mỗi cây, đảm bảo mô hình không bị quá khớp.
- + `subsample`: 0.8 - Tỷ lệ mẫu được sử dụng trong mỗi cây, giúp mô hình tổng quát hơn.
- + `colsample_bytree`: 0.8 - Tỷ lệ cột được sử dụng, giảm thiểu sự tương quan giữa các cây.
- + `objective`: `reg:squarederror` - Hàm mất mát sử dụng để tối ưu hóa hồi quy.
- + `random_state`: 42 - Đảm bảo tính nhất quán khi lặp lại quá trình huấn luyện.

Việc lựa chọn các tham số này được thực hiện thông qua quá trình tối ưu hóa Grid Search và Randomized Search CV, nhằm tìm ra sự kết hợp tham số tốt nhất để đạt được độ chính xác cao mà không gây ra hiện tượng quá khớp (overfitting).

3.2.3. Quy trình thực hiện

Đầu tiên, dữ liệu log-return được kiểm tra để đảm bảo không có giá trị bị thiếu hoặc bất thường. Các giá trị thiếu được loại bỏ hoặc thay thế bằng cách sử dụng các kỹ thuật nội suy hoặc điền giá trị trung bình. Dữ liệu được chuẩn hóa để tránh hiện tượng mô hình bị lệch do sự khác biệt về đơn vị đo lường giữa các coin. Chuyển đổi log-return thành giá dự báo thông qua tích lũy log-return (sử dụng hàm mũ tích lũy). Phép chuyển

đổi này đảm bảo rằng các thay đổi logarit được tổng hợp thành giá thực tại từng thời điểm.

Dữ liệu sau khi chuyển đổi được chia thành hai tập: Tập huấn luyện (80%) (Dùng để huấn luyện mô hình, bao gồm các mẫu log-return và giá tương ứng) và Tập kiểm tra (20%) (Được sử dụng để đánh giá hiệu quả của mô hình trên các mẫu chưa từng thấy).

Mô hình được sử dụng trong nghiên cứu là XGBoost Regressor, một phương pháp boosting mạnh mẽ trong các bài toán hồi quy. Mô hình được tích hợp trong cấu trúc MultiOutputRegressor để dự báo đồng thời nhiều biến (ba coin). Các siêu tham số của mô hình được tối ưu hóa thông qua Grid Search và Randomized Search CV, giúp tìm ra các giá trị tốt nhất cho các tham số như `n_estimators`, `learning_rate`, `max_depth`, `subsample`, và `colsample_bytree`.

Mô hình được huấn luyện với tối ưu hóa Gradient Boosting, nhằm giảm thiểu lỗi dự báo thông qua việc kết hợp nhiều cây quyết định nhỏ (weak learners) và để nhằm đảm bảo mô hình không bị quá khớp (overfitting), quá trình huấn luyện được giám sát bằng cách sử dụng tập kiểm tra nhỏ trong quá trình huấn luyện.

Sau khi huấn luyện, mô hình được áp dụng trên tập kiểm tra để dự báo log-return trong 24 giờ tiếp theo. Hiệu quả mô hình được đánh giá dựa trên sự so sánh giữa giá trị thực tế và giá trị dự báo, nhằm nhận diện những điểm yếu của mô hình. Các chỉ số đánh giá mô hình được tính toán bao gồm:

- + MSE (Mean Squared Error): Đo lường sai số trung bình bình phương giữa giá trị thực tế và dự báo.

- + R^2 (Hệ số xác định): Đo lường mức độ giải thích của mô hình đối với biến mục tiêu.

- + VaR (Value at Risk): Đo lường mức lỗ tối đa có thể xảy ra với một độ tin cậy nhất định.

- + ES (Expected Shortfall): Đánh giá tổn thất trung bình trong những trường hợp xấu nhất vượt qua mức VaR.

+ MDD (Maximum Drawdown): Đo lường mức sụt giảm lớn nhất từ đỉnh đến đáy trong quá trình dự báo giá.

3.3. Kết quả phân tích

3.3.1. Hiệu suất mô hình

MSE (Mean Squared Error): $4.4571e-05$ - Mức độ sai số khá thấp, cho thấy mô hình có khả năng dự báo tương đối ổn định.

R^2 (Hệ số xác định): -0.0664 - Giá trị âm, cho thấy mô hình chưa tối ưu hóa tốt và có khả năng dự báo kém trên tập kiểm tra.

Mặc dù MSE có giá trị khá nhỏ, điều đó cho thấy mô hình có khả năng giảm thiểu độ sai lệch giữa giá trị thực tế và dự báo, nhưng việc R^2 âm lại phản ánh rằng mô hình không nắm bắt được xu hướng tổng thể của dữ liệu. Giá trị MSE nhỏ nhưng R^2 âm cho thấy mô hình có thể đang cố gắng dự báo chính xác những dao động nhỏ, nhưng lại không nắm bắt được xu hướng chung của giá. Điều này có thể xuất phát từ việc mô hình quá tập trung vào việc tối ưu hóa các điểm nhỏ lẻ mà không chú trọng đến xu hướng lớn. Điều này cũng có nghĩa là mô hình không tổng quát hóa tốt trên tập kiểm tra và có thể đã bị quá khớp trên tập huấn luyện.

3.3.2. Dự báo kết quả

⇒ Dự báo log-return (24h, 3 coin):

[-2.0151567e-03	-2.4438701e-03	1.3241791e-03]
[-6.3409243e-04	-1.0790813e-03	-6.4208085e-04]
[-1.4473987e-03	-1.2343169e-04	3.4512285e-04]
[-1.2876406e-04	-2.4747520e-04	1.2199885e-03]
[-9.1778429e-04	7.6712000e-05	-7.5683539e-04]
[5.0718733e-04	3.2364842e-04	-7.9750124e-04]
[-2.7746166e-04	-2.4085608e-03	1.8700998e-04]
[5.4437749e-04	2.6182350e-04	-7.4073445e-04]
[-1.4425897e-03	-1.4599060e-03	-5.8320293e-04]
[-9.8195917e-04	1.0122309e-03	-1.3312139e-03]
[1.5659509e-05	2.8864534e-03	2.2282512e-03]
[2.4408509e-03	9.3343022e-04	9.9630805e-04]
[5.0752721e-04	-1.4074139e-03	5.8506610e-04]
[-3.5505064e-04	1.1735385e-03	-4.9293437e-03]
[8.1295689e-04	1.7180961e-03	1.6118916e-03]
[-1.2621145e-03	-3.7507121e-03	-3.7447556e-03]
[9.1736857e-04	-1.7072441e-03	-1.0783396e-03]
[5.4028950e-04	4.8715486e-03	1.0694730e-03]
[5.9590087e-04	-1.6012576e-03	1.8218275e-04]
[1.1162279e-03	-1.2128686e-03	1.2344840e-03]
[-5.0439005e-04	-9.7056245e-04	1.5749225e-03]
[4.1884684e-04	-2.0107585e-03	-1.2842717e-03]
[2.6479774e-04	-4.0633772e-03	-8.3961990e-04]
[-1.5977072e-05	-4.2087922e-05	-1.7610515e-03]

Hình 3.3.2. Kết quả dự báo log-return 24 giờ tiếp theo

Chuỗi log-return dự báo được biểu diễn dưới dạng một mảng 2D với kích thước (24, 3), trong đó mỗi hàng tương ứng với 24 giờ dự báo liên tiếp, còn mỗi cột tương ứng với một loại tiền điện tử (Coin 1, Coin 2, Coin 3). Để hiểu rõ hơn về xu hướng và mức độ biến động của từng đồng tiền điện tử, chúng tôi tiến hành phân tích cụ thể như sau:

+ Coin 1: Coin 1 có chuỗi log-return dao động trong khoảng từ -0.0016 đến 0.0050. Các giá trị log-return chủ yếu dao động nhẹ xung quanh mức 0, cho thấy sự ổn định tương đối của đồng tiền này. Với biên độ biến động không quá lớn, Coin 1 thể hiện tính ổn định cao hơn so với hai loại coin còn lại. Điều này cho thấy Coin 1 ít chịu tác động từ các cú sốc ngắn hạn và có thể phù hợp với các chiến lược đầu tư dài hạn hoặc các danh mục có độ rủi ro thấp.

+ Coin 2: Chuỗi log-return của Coin 2 dao động từ -0.0042 đến 0.0032, cho thấy mức độ biến động khá lớn. Đặc biệt, có nhiều giá trị log-return âm hơn so với dương, điều này ngụ ý rằng Coin 2 có xu hướng suy giảm giá trị nhiều hơn là tăng trưởng. Sự biến động này có thể do ảnh hưởng từ các yếu tố nội tại của đồng coin hoặc những sự kiện không lường trước trên thị trường tiền điện tử. So với Coin 1, Coin 2 có mức độ bất ổn định cao hơn, khiến việc dự báo trở nên khó khăn hơn và cần có các chiến lược phòng ngừa rủi ro thích hợp.

+ Coin 3: Coin 3 là đồng tiền có mức độ biến động mạnh nhất trong ba loại coin được phân tích, với chuỗi log-return dao động từ -0.0084 đến 0.0058. Điều này cho thấy biên độ dao động cao, dễ gặp phải các cú sốc giá lớn. Sự biến động mạnh của Coin 3 làm cho quá trình dự báo trở nên phức tạp và không ổn định. Việc dự báo chính xác với đồng coin này đòi hỏi mô hình phải có khả năng thích ứng với các dao động lớn và bất thường, có thể sử dụng thêm các mô hình phi tuyến như LSTM hoặc GRU để nắm bắt tốt hơn.

Qua phân tích chuỗi log-return của ba loại tiền điện tử, chúng ta thấy rõ sự khác biệt về tính ổn định và xu hướng biến động. Coin 1 có độ ổn định cao nhất, với mức biến động nhỏ và ít chịu ảnh hưởng từ các cú sốc thị trường. Trong khi đó, Coin 2 có mức độ biến động trung bình với xu hướng giảm nhẹ, còn Coin 3 là loại coin có độ biến động lớn nhất, khó kiểm soát và dự báo. Về xu hướng giá thì Coin 1 thể hiện khả năng giữ giá tốt hơn trong ngắn hạn, trong khi Coin 2 cho thấy dấu hiệu suy giảm giá trị. Coin 3 thì biến động mạnh, có xu hướng không ổn định trong khoảng thời gian 24 giờ được dự báo.

Mô hình XGBoost sử dụng trong nghiên cứu đã cho thấy khả năng dự báo khá ổn định đối với Coin 1, tuy nhiên gặp khó khăn với Coin 2 và Coin 3 do biến động mạnh. Điều này phản ánh rằng mô hình có thể không đủ mạnh trong việc nắm bắt các xu hướng giá ngắn hạn của các loại tiền điện tử biến động cao. Để cải thiện kết quả dự báo, cần xem xét việc kết hợp thêm các mô hình học sâu (như LSTM hoặc GRU) hoặc áp dụng các mô hình phi tuyến để giải quyết các biến động khó lường.

3.3.3. Phân tích rủi ro

```
Giá dự báo (24 giờ, 3 coin):
tensor([[30510.1230, 1915.9718, 246.8767],
        [30490.7773, 1913.9055, 246.7182],
        [30446.6777, 1913.6693, 246.8834],
        [30442.7578, 1913.1959, 247.1047],
        [30414.8320, 1913.3425, 246.9177],
        [30430.2598, 1913.9619, 246.7209],
        [30421.8184, 1909.3575, 246.7670],
        [30438.3867, 1909.8574, 246.5843],
        [30394.5039, 1907.0712, 246.4405],
        [30364.6758, 1909.0026, 246.1127],
        [30365.1484, 1914.5208, 246.6617],
        [30439.3574, 1916.3090, 246.9076],
        [30454.8105, 1913.6136, 247.0521],
        [30443.9980, 1915.8607, 245.8373],
        [30468.7598, 1919.1553, 246.2339],
        [30430.3281, 1911.9705, 245.3135],
        [30458.2559, 1908.7091, 245.0491],
        [30474.7188, 1918.0303, 245.3113],
        [30492.8848, 1914.9614, 245.3560],
        [30526.9395, 1912.6401, 245.6591],
        [30511.5449, 1910.7848, 246.0463],
        [30524.3281, 1906.9465, 245.7305],
        [30532.4121, 1899.2133, 245.5243],
        [30531.9238, 1899.1335, 245.0923]])
VaR(5%): -0.0032049291767179966
ES(5%): -0.004113514441996813
Cumulative PnL (tương đối) cho 3 coin: tensor([ 0.0007, -0.0088, -0.0072])
Maximum Drawdown cho 3 coin: [0.00476718 0.01043257 0.00831869]
<ipython-input-30-599641aed81b>:12: DeprecationWarning: __array_wrap__ must accept context and return_scalar arguments (positionally) in the future. (Deprecated NumPy 2.0)
price_path = init_price * np.exp(cum_log)
```

Hình 3.3.3. Các chỉ số rủi ro với mức ý nghĩa 5%

VaR (5%): -0.0032 (-0.32%) - Độ lỗ tối đa có thể xảy ra với độ tin cậy 95%.

ES (5%): -0.0041 (-0.41%) - Trung bình lỗ trong các trường hợp xấu nhất.

Nhận xét: Giá trị VaR 5% cho thấy trong 95% trường hợp, mức lỗ tối đa không vượt quá 0.32%, nhưng trong 5% trường hợp tồi tệ nhất, mức lỗ trung bình là 0.41% (ES). Sự chênh lệch giữa VaR và ES cho thấy rằng trong những tình huống xấu nhất, tổn thất có thể vượt mức VaR đáng kể, điều này chỉ ra sự xuất hiện của các cú sốc lớn trên thị trường. Các chỉ số này đều âm, phản ánh rủi ro thua lỗ lớn trong các tình huống bất lợi, nhất là khi biến động giá xảy ra đột ngột.

3.3.4. Kiểm tra tính đồng nhất của dữ liệu log-return và giá ban đầu

```
--- Checking index 0 ---
log_returns[idx] shape: (24, 3)
init_price_data[idx]: tensor([[26489.4453, 1840.9900, 261.9500]])

--- Checking index 100 ---
log_returns[idx] shape: (24, 3)
init_price_data[idx]: tensor([[48071.5898, 2494.5200, 319.5500]])


--- Checking index 500 ---
log_returns[idx] shape: (24, 3)
init_price_data[idx]: tensor([[9577.4805, 192.7350, 18.7819]])

--- Checking index -1 ---
log_returns[idx] shape: (24, 3)
init_price_data[idx]: tensor([[30571.6641, 1920.6600, 246.5500]])
```

Hình 3.3.4. Kiểm tra tính đồng nhất

Kiểm tra tính đồng nhất giữa các dữ liệu `log_returns` và `init_price_data` để đảm bảo rằng dữ liệu đầu vào và đầu ra được căn chỉnh chính xác. Các kiểm tra cho thấy rằng kích thước của `log_returns` và `init_price_data` đều nhất quán. Không có sự sai lệch về định dạng hoặc kích thước dữ liệu giữa các chỉ số được chọn.

3.3.5. Đồ thị và phân tích trực quan



Hình 3.3.5. Biểu đồ phân phối log-return (Hourly)


Biểu đồ trên là biểu đồ tần suất của log-return hàng giờ của các đồng tiền điện tử trong khoảng thời gian dự báo 24 giờ. Trục hoành (Return) biểu thị giá trị log-return, trong khi trục tung (Tần suất) biểu thị số lượng các giá trị log-return tương ứng trong từng khoảng giá trị. Đường thẳng đứng màu đỏ (dashed line) đại diện cho giá trị VaR (5%) = -0.0024.

Phân phối log-return hàng giờ tập trung rất cao ở vùng trung tâm gần giá trị 0, cho thấy rằng trong hầu hết các khoảng thời gian, tỷ suất sinh lợi có xu hướng dao động quanh mức không thay đổi nhiều. Phân phối có dạng phân phối chuẩn hẹp, với phần lớn

các giá trị log-return nằm trong khoảng $[-0.002, 0.002]$. Đuôi phân phối khá ngắn, phản ánh rằng các cú sốc thị trường hoặc biến động mạnh ít xảy ra. Giá trị VaR (5%) = -0.0024 biểu thị rằng trong 95% thời gian, mức lỗ hàng giờ không vượt quá 0.24%. VaR được đánh dấu bằng đường thẳng đứng màu đỏ, nằm ở phía bên trái của phân phối, thể hiện mức cắt lỗ tiềm năng trong điều kiện bất lợi. Các log-return nằm bên trái của đường VaR đại diện cho những tình huống xấu nhất (tức là những cú sốc bất lợi mạnh).

Mật độ tần suất tập trung rất cao ở vùng gần 0, cho thấy phần lớn các biến động giá là nhỏ và ổn định. Điều này có thể ám chỉ rằng mặc dù thị trường có biến động nhưng đa phần là các biến động nhỏ lẻ, không tạo ra các cú sốc lớn. Mặc dù phần lớn các log-return gần 0, nhưng sự xuất hiện của các điểm bất lợi (bên trái đường VaR) vẫn là yếu tố đáng lo ngại. Điều này cho thấy thị trường có tiềm năng xảy ra các cú sốc nhỏ nhưng bất ngờ. Việc sử dụng VaR (5%) cung cấp một cái nhìn tương đối về mức độ rủi ro, nhưng có thể chưa phản ánh hết được các cú sốc bất thường ngoài 5%. Trong trường hợp đó, việc sử dụng thêm Expected Shortfall (ES) sẽ giúp làm rõ hơn các tổn thất trung bình trong điều kiện xấu nhất.

Từ kết quả phân tích, một số khuyến nghị được đưa ra nhằm quản lý rủi ro và tăng cường mô hình dự báo. Thứ nhất, cần thiết lập các mức cắt lỗ (stop-loss) để bảo vệ danh mục trong trường hợp log-return giảm quá mức VaR. Để đảm bảo an toàn, có thể kết hợp quản lý danh mục động với việc dự đoán biến động theo thời gian thực. Thứ hai, do phân phối tập trung mạnh ở mức 0, mô hình XGBoost có thể đã quá tập trung vào việc tối ưu hóa các giá trị gần trung tâm mà bỏ qua các cú sốc cực đoan. Để cải thiện, có thể sử dụng các mô hình học sâu như LSTM hoặc GRU để nắm bắt các dao động ngắn hạn và bất thường. Cuối cùng, để giảm thiểu rủi ro từ các cú sốc đột ngột, cần thực hiện đa dạng hóa danh mục thay vì đầu tư tập trung vào một hoặc hai loại coin có mức biến động mạnh.




So sánh dự báo giá Coin 1 với thực tế

Biểu đồ trên thể hiện sự so sánh giữa giá thực tế (Actual Price) và giá dự báo (Predicted Price) của Coin 1 trong khoảng thời gian dự báo 24 giờ tiếp theo. Đường màu xanh lá cây (Actual Price) biểu diễn chuỗi giá thực tế của Coin 1, trong khi đường màu xanh dương nét đứt (Predicted Price) biểu diễn chuỗi giá dự báo. Quan sát biểu đồ cho thấy đường dự báo có xu hướng nằm thấp hơn so với đường giá thực tế trong hầu hết khoảng thời gian, đặc biệt là trong khoảng từ giờ thứ 12 đến 24, khi giá thực tế tăng lên đáng kể trong khi giá dự báo vẫn duy trì ở mức thấp. Điều này cho thấy sự sai lệch giữa giá thực tế và giá dự báo càng trở nên rõ ràng hơn ở các điểm giá cao.

Trong giai đoạn đầu (khoảng giờ thứ 0 đến 12), cả hai đường giá đều thể hiện xu hướng giảm, tuy nhiên, biên độ giảm của đường dự báo lớn hơn so với giá thực tế. Trong giai đoạn sau (giờ thứ 12 đến 24), giá thực tế cho thấy xu hướng tăng mạnh, trong khi giá dự báo chỉ tăng nhẹ và không theo kịp xu hướng chung. Độ chính xác của mô hình dự báo tương đối thấp, đặc biệt là khi giá trị tăng mạnh, cho thấy khả năng của mô hình trong việc nắm bắt các xu hướng giá tăng là không tốt. Việc mô hình không theo kịp xu hướng tăng có thể xuất phát từ việc mô hình quá tập trung vào các dao động nhỏ hoặc chưa được tối ưu hóa để phản ánh các biến động lớn trên thị trường.

Mô hình có xu hướng bỏ lỡ các xu hướng tăng mạnh, thể hiện qua việc đường dự báo luôn nằm dưới đường thực tế trong phần lớn thời gian. Giá dự báo có sự dao động nhỏ hơn so với giá thực tế, điều này có thể do mô hình quá nhạy với các thay đổi nhỏ nhưng lại không phản ánh được các biến động lớn. Khả năng nắm bắt xu hướng giảm tốt hơn so với xu hướng tăng, nhưng độ chính xác vẫn chưa đạt yêu cầu.




So sánh dự báo giá Coin 2 với thực tế

Biểu đồ trên thể hiện sự so sánh giữa giá thực tế (Actual Price) và giá dự báo (Predicted Price) của Coin 2 trong khoảng thời gian dự báo 24 giờ tiếp theo. Đường màu xanh lá cây (Actual Price) biểu diễn chuỗi giá thực tế của Coin 2, trong khi đường màu xanh dương nét đứt (Predicted Price) biểu diễn chuỗi giá dự báo.

Quan sát biểu đồ cho thấy mô hình dự báo có xu hướng dự báo thấp hơn giá trị thực tế, đặc biệt là khi giá có xu hướng tăng mạnh. Cụ thể, trong khoảng thời gian từ giờ thứ 0 đến 8, cả hai đường đều cho thấy xu hướng giảm nhẹ và tương đối khớp nhau. Tuy nhiên, trong khoảng từ giờ thứ 8 đến 16, giá thực tế có xu hướng tăng nhẹ nhưng đường dự báo lại đi xuống, thể hiện sự khác biệt rõ rệt về xu hướng giữa dự báo và thực tế. Đáng chú ý nhất là trong khoảng từ giờ thứ 18 đến 24, giá thực tế tăng mạnh, đạt đỉnh tại khoảng giờ thứ 23, trong khi giá dự báo không phản ánh được xu hướng tăng đột biến này và thậm chí còn giảm. Điều này thể hiện rằng mô hình chưa nắm bắt được các biến động mạnh của thị trường, đặc biệt là trong các giai đoạn tăng giá nhanh.

Biên độ dao động của giá thực tế cũng lớn hơn đáng kể so với giá dự báo, điều này cho thấy mô hình có xu hướng làm trơn các biến động và chưa phản ánh được độ nhạy của thị trường. Mặc dù trong một số khoảng thời gian ngắn hạn, hai đường có xu hướng gần nhau, nhưng nhìn chung, mô hình chưa đủ mạnh để nhận diện các xu hướng tăng đột biến hoặc các pha chuyển đổi nhanh từ giảm sang tăng. Điều này có thể là kết quả của việc mô hình quá tập trung vào các mẫu huấn luyện có xu hướng ít biến động.



So sánh dự báo giá Coin 3 với thực tế

Biểu đồ trên thể hiện sự so sánh giữa giá thực tế (Actual Price) và giá dự báo (Predicted Price) của Coin 3 trong khoảng thời gian dự báo 24 giờ tiếp theo. Đường màu xanh lá cây (Actual Price) biểu diễn chuỗi giá thực tế của Coin 3, trong khi đường màu xanh dương nét đứt (Predicted Price) biểu diễn chuỗi giá dự báo.

Quan sát biểu đồ cho thấy có sự khác biệt khá rõ rệt giữa giá dự báo và giá thực tế, đặc biệt là trong những thời điểm có biến động mạnh. Mô hình có xu hướng dự báo giá cao hơn thực tế trong khoảng từ giờ thứ 0 đến 10. Trong khoảng thời gian này, mặc dù giá thực tế có xu hướng giảm nhẹ, giá dự báo lại tương đối ổn định hoặc tăng nhẹ. Điều này cho thấy mô hình chưa nắm bắt được xu hướng giảm rõ rệt trong giai đoạn đầu.

Trong khoảng giờ thứ 11 đến 16, giá thực tế trải qua một giai đoạn giảm mạnh và sau đó tăng vọt, trong khi giá dự báo vẫn duy trì sự ổn định và không theo kịp xu hướng biến động. Sự khác biệt này chỉ ra rằng mô hình có xu hướng làm mượt dữ liệu, làm giảm độ nhạy với các dao động đột ngột. Đặc biệt, từ giờ thứ 16 đến 24, giá thực tế phục hồi mạnh mẽ và đạt đỉnh vào giờ thứ 23. Tuy nhiên, giá dự báo lại tiếp tục giảm hoặc không tăng tương ứng, cho thấy khả năng dự đoán xu hướng đảo chiều của mô hình còn nhiều hạn chế. Điều này có thể do mô hình chưa được tối ưu hóa đủ để nhận diện các yếu tố làm thay đổi nhanh chóng xu hướng thị trường.

CHƯƠNG 4: KẾT LUẬN VÀ KHUYẾN NGHỊ

4.1. Khuyến nghị về lựa chọn đồng coin

4.1.1. Ưu tiên các đồng coin có biến động ổn định và thanh khoản cao

(Ví dụ: Bitcoin, Ethereum...)

Các đồng coin này thường có khối lượng giao dịch lớn, giá biến động ổn định hơn, và thường được giao dịch trên nhiều sàn, do đó có thể đảm bảo tính thanh khoản cao. Điều này giúp giảm thiểu rủi ro khi thực hiện các chiến lược giao dịch ngắn hạn, nhất là trong các môi trường thị trường không ổn định.

4.1.2. Cẩn trọng với các đồng coin có biến động mạnh

Nếu bạn có khẩu vị rủi ro cao và sử dụng các chiến lược giao dịch linh hoạt như giao dịch theo xu hướng (trend following) hoặc scalping, có thể cân nhắc các đồng coin có biến động mạnh.

Tuy nhiên, cần chú ý rằng các đồng coin này dễ bị tác động bởi các yếu tố ngẫu nhiên và tin tức thị trường, do đó rủi ro mất mát cũng cao hơn.

4.1.3. Đánh giá các yếu tố cơ bản (fundamental analysis)

Theo dõi các chỉ số về khối lượng giao dịch, sự phát triển của cộng đồng, công nghệ và ứng dụng thực tiễn của từng đồng coin.

Các đồng coin có lịch sử phục hồi nhanh sau các đợt giảm mạnh và cho thấy xu hướng tăng trưởng dài hạn thường là lựa chọn hấp dẫn cho giao dịch trung – dài hạn.

4.2. Khuyến nghị về quản trị rủi ro

4.2.1. Sử dụng các chỉ số định lượng để đo lường rủi ro

Sử dụng VaR để đánh giá mức lỗ tối đa có thể xảy ra với một xác suất nhất định (thường là 5% hoặc 1%). ES cung cấp thông tin bổ sung bằng cách tính trung bình mức lỗ trong trường hợp xấu nhất, giúp người giao dịch có cái nhìn toàn diện về rủi ro. Nếu một đồng coin có VaR và ES cao, nên cân nhắc giảm khối lượng giao dịch hoặc áp dụng các biện pháp bảo vệ như stop loss, hedging.

4.2.2. Quan sát các chỉ số rủi ro bổ sung

Maximum Drawdown (MDD): Cho biết mức giảm giá tối đa từ đỉnh đến đáy, giúp xác định khả năng phục hồi của đồng coin.

Cumulative PnL (Lợi nhuận tích lũy): Đánh giá tổng hiệu suất giao dịch qua thời gian.

Những coin có MDD thấp và xu hướng PnL tăng dần có thể là những lựa chọn an toàn và hiệu quả hơn trong giao dịch.

4.2.3. Quản trị danh mục đầu tư

Không nên “đặt tất cả trứng vào một giỏ”. Một danh mục đa dạng với các đồng coin có mức rủi ro và biến động khác nhau giúp phân tán rủi ro.

Áp dụng chiến lược phân bổ rủi ro dựa trên biến động, khối lượng giao dịch và các chỉ số rủi ro đã nêu, nhằm tối ưu hóa lợi nhuận đồng thời hạn chế thua lỗ trong các giai đoạn thị trường không thuận lợi.

TÀI LIỆU THAM KHẢO

(XGBoost – Mọi thứ bạn cần biết về ứng dụng của XGBoost, n.d.)

(A machine learning analysis of COVID-19 mental health data, n.d.)

(The Power of Words: Predicting Stock Market Returns with Fine-Grained Sentiment Analysis and XGBoost, n.d.)

(Mô phỏng nồng độ bụi PM2.5 tại khu vực trung tâm Thành phố, n.d.)

(NGHIÊN CỨU MỘT SỐ PHƯƠNG PHÁP HỌC MÁY TRONG THÀNH LẬP BẢN ĐỒ LỚP PHỦ BỀ MẶT TỈNH CÀ MAU TRÊN NỀN TẢNG GOOGLE EARTH ENGINE, n.d.)

(Thuật toán tăng cường là gì?, n.d.)

(Dự báo giá cổ phiếu CATL đóng cửa và các chiến lược giao dịch sử dụng XGBoost và thuật toán tối ưu hóa Optuna, n.d.)

(The_Power_of_Words_Predicting_Stock_Market_Returns_with_Fine-Grained_Sentiment_Analysis_and_XGBoost, n.d.)

(Gradient Boosting - Tất tần tật về thuật toán mạnh mẽ nhất trong Machine Learning, n.d.)

(Mô phỏng nồng độ bụi PM2.5 tại khu vực trung tâm Thành phố Hồ Chí Minh bằng thuật toán học máy và học sâu, n.d.)

(MÔ HÌNH CHẨN ĐOÁN BỆNH COVID-19 TỪ DỮ LIỆU LÂM SÀNG BẰNG PHƯƠNG PHÁP XGBOOST, n.d.)